

数据之用：从数据到模型

Yuchen Zhang

整理日期：2026 年 9 月 16 日

1 数据为什么有用

本讲的主线是：把实际问题转化为数据问题，再用数学模型支持预测和决策。

实际问题 → 收集与处理数据 → 发现结构
→ 建立模型 → 验证模型 → 预测与决策

1.1 数据、信息与知识

- **数据**：对事物的记录，如某个时刻的天体位置、用户对电影的评分。
- **信息**：数据在具体语境中表达的意义，如从连续观测中发现运动轨迹，或从评分中发现偏好。
- **知识**：对信息进一步组织、解释后形成的认识，如能够描述和预测现象的规律。

数据是信息的载体，但数据多不等于有效信息多。随机数字、重复记录、错误记录，未必能帮助解决目标问题。

1.2 大数据的特点与处理

课堂涉及四个方面：**规模大、产生和更新快、类型多、蕴含可挖掘的价值**。例如平台持续产生大量文字、图像、评分与行为记录，经过分析可以支持推荐和预测。

建模前要检查数据的缺失、噪声、异常、真实性及与任务的关联。一个能解释已有数据的模型，还应接受新数据的检验；已有数据上的吻合不自动保证未来预测准确。

1.3 案例的共同作用

天体观测说明数据为模型提供依据，也帮助比较不同解释；人工智能案例说明数据、模型和算法需要配合。学习重点是说明**用了什么数据、解决什么问题、依赖什么假设、怎样验证**，不必把案例中的历史数字作为本讲的核心记忆负担。

2 推荐系统：把偏好预测写成矩阵补全

2.1 三类数据矩阵

- **评分矩阵**：行对应用户，列对应物品，元素表示用户对物品的评分或偏好。
- **用户信息矩阵**：行对应用户，列对应用户属性。
- **物品信息矩阵**：行对应物品，列对应物品属性，如电影类别。

本讲重点讨论基于评分矩阵的推荐模型；用户和物品属性可作为辅助信息。这是推荐系统的一种建模方式，不意味着所有推荐算法都必须显式使用评分矩阵。

设有 m 个用户、 n 件物品。记已观测评分为 M_{ij} ，其位置集合为

$$\Omega = \{(i, j) : \text{用户 } i \text{ 对物品 } j \text{ 的评分已知}\}.$$

缺失不等于零分。缺失表示不知道；已知零分也是观测，必须纳入 Ω 。任务是预测未知位置的评分，再将预测评分较高的物品推荐给相应用户。

2.2 低秩假设

定义 2.1. 矩阵的秩是其线性无关列的最大数量，也等于线性无关行的最大数量。若秩相对于矩阵行、列数较小，就称其具有低秩结构。

直观上，很多用户的偏好可能由少数共同因素解释，因此评分之间存在相关结构，可以尝试用低秩矩阵描述。**低秩是建模假设**，不能仅凭“人以群分”就断言实际评分矩阵必然低秩。

不要混淆两种性质：观测稀疏指已知评分少；低秩指矩阵行列之间有较强的线性关联。空缺很多不会自动推出补全结果低秩。

2.3 目标函数与约束

记待求的完整评分矩阵为 $X \in \mathbb{R}^{m \times n}$ 。课堂中的理想化模型为

$$\min_X \text{rank}(X) \quad \text{满足 } X_{ij} = M_{ij}, \quad (i, j) \in \Omega.$$

目标函数要求补全结果尽可能低秩；**约束条件**要求保留已知评分。未知位置虽没有观测等式约束，仍受整个矩阵低秩目标的影响。只有“低秩”这一条件，通常不足以保证能唯一恢复真实评分。

3 从秩到核范数

3.1 用更易处理的目标替代原目标

定义 3.1. 设矩阵 X 的奇异值为 $\sigma_1, \dots, \sigma_r$, 其中 $r = \min(m, n)$, 允许其中有零。则

$$\text{rank}(X) = \#\{k : \sigma_k > 0\}, \quad \|X\|_* = \sum_{k=1}^r \sigma_k.$$

$\|X\|_*$ 称为 X 的核范数。

直接最小化秩通常难以求解。课堂介绍的思路是改用核范数, 形成凸优化替代模型:

$$\min_X \|X\|_* \quad \text{满足 } X_{ij} = M_{ij}, \quad (i, j) \in \Omega.$$

秩数的是非零奇异值的**个数**, 核范数计算奇异值的**总和**。核范数最小化用于促进低秩结构, 但两个问题**不在一般情况下等价**; 是否恢复真实矩阵, 还取决于观测数量、位置和矩阵结构等条件。

本讲先理解建模与替代的思想即可, 奇异值分解的具体计算和求解算法不在这份导论笔记中展开。

3.2 补充辨析: 不能一般地用特征值数秩

例题 3.2. 矩阵 $A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ 的秩是多少?

解: 只有第二列非零, 所以 $\text{rank}(A) = 1$ 。但其两个特征值均为零。因此, “方阵的秩等于非零特征值的个数”不是一般成立的结论。对任意实矩阵, 使用非零**奇异值**的个数计算秩是正确的。

3.3 补充例题: 怎样理解缺失值与低秩

给定 $M = \begin{pmatrix} 5 & ? \\ 5 & 3 \end{pmatrix}$, 假设补全结果的秩为 1。若 $X = \begin{pmatrix} 5 & x \\ 5 & 3 \end{pmatrix}$, 则两列线性相关, 故

$$\det X = 15 - 5x = 0, \quad x = 3.$$

这里的结果依赖秩为 1 的假设。若直接把问号填成 0, 就额外假定了未知评分为零, 且所得矩阵的秩变为 2。此例用于理解模型, 不代表实际推荐都能这样精确补全。

4 预测与决策案例

4.1 搜索数据与流感趋势预测

课堂以搜索记录辅助预测流感趋势为例。传统统计存在时间延迟，相关搜索量可能提供较及时的信号。基本流程为：

1. 确定预测目标，例如某地区某时期的流感活动水平。
2. 从搜索记录中选取可能相关的关键词或统计特征。
3. 利用历史特征与对应观测建立预测模型。
4. 将预测与实际观测比较，检验误差和适用范围。

用统一符号表示，简单的线性预测模型可以写为

$$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p,$$

其中 x_j 是输入特征， $\hat{y}$ 是预测值， β_j 是待估计参数。此式是对课堂思路的标准化表达，不要求本讲掌握参数求解。

特征必须服务于目标。例如评选班干部时，组织能力和责任心可能有用，血型或身高通常不能直接说明是否胜任。特征选择是从候选特征中挑选子集；更广义的特征提取还可构造新的表示，两者不宜完全混同。

搜索量也会受到新闻关注、搜索习惯等因素影响。因此相关性带来的预测能力需要持续验证，不能把一个案例理解为“搜索越多就一定感染越多”。

4.2 其他应用及其共同边界

- **药物用途探索：**从数据中寻找新的候选关联，为后续研究提供线索；数据关联本身不能替代实验和临床验证。
- **广告匹配：**根据用户、广告及场景信息选择可能更合适的展示内容，体现数据对决策的支持。
- **购物关联分析：**发现共同购买模式，为陈列或推荐提供参考；课堂故事用于解释思路，不据此认定因果关系。

相关不等于因果。两个现象一起变化，可能受共同因素影响。模型既要看数据中的规律，也要考虑规律能否在新的时间、群体和环境继续成立。

5 闭卷自测与第一讲补习

以下问题按本讲内容整理，**不是教师公布的试题或考试范围**。先合上笔记口头回答，再核对要点。

1. **数据多为什么不一定有价值？**

要点：数据可能重复、错误或无关；需结合任务进行处理、建模和验证，才能支持决策。

2. **评分矩阵的行、列和缺失位置各表示什么？**

要点：用户、物品、未知偏好；缺失不能直接当作零分。

3. **观测稀疏与低秩有什么区别？**

要点：前者是已知元素少，后者是行列之间的线性关联；两者不等价。

4. **矩阵补全的目标函数和约束各是什么？**

要点：最小化补全矩阵的秩；在 Ω 上保持已知评分一致。能写出模型并逐项解释。

5. **为什么引入核范数？**

要点：直接优化秩通常困难；核范数是奇异值之和，可作为促进低秩的凸替代目标，但不保证一般等价。

6. **搜索数据怎样用于预测？**

要点：确定目标、选择相关特征、建立模型、对照实际观测检验；注意数据关系可能改变。

7. **数据发现的关联能直接当作因果吗？**

要点：不能；可能存在共同因素，需要额外研究和验证。

5.1 一次补习的完成标准

先读第 1 节掌握主线，再把第 2、3 节的两个优化模型默写一次，说明每个符号和约束的含义；最后用“问题—数据—模型—验证—局限”复述一个预测案例。能够独立回答以上问题，再回听仍不清楚的片段即可。

5.2 课程安排备忘

录音中提到前七周授课、第八周闭卷随堂考试，可能包含论述和模型解释。作业、成绩构成及考试范围以教师或教学大纲确认为准。

资料说明：根据两段课堂录音转录整理，省略识别不稳的历史数字与板书坐标。补充例题用于理解；课程名为描述性名称，1.1 为整理编号。